10.1 引 言

1. 单处理机系统结构正在走向尽头？

2. 多处理机正起着越来越重要的作用。近几年来，人们确实开始转向了多处理机。

   - Intel于2004年宣布放弃了其高性能单处理器项目，转向多核（multi-core）的研究和开发。
   - IBM、SUN、AMD等公司
   - 并行计算机应用软件已有了稳定的发展。
   - 充分利用商品化微处理器所具有的高性能价格比的优势。

3. 本章重点：中小规模的计算机(处理器的个数＜32)

   （多处理机设计的主流）

We are dedicating all of our future product development to multicore designs. We believe this is a key inflection point for the industry.

Intel President Paul Otellini,
describing Intel's future direction at the Intel Developers Forum in 2005

The Teraflops Research Chip

Frequency	Voltage	Power	Aggregate Bandwidth	Performance
3.16 GHz	0.95 V	62W	1.62 Terabits/s	1.01 Teraflops
5.1 GHz	1.2 V	175W	2.61 Terabits/s	1.63 Teraflops
5.7 GHz	1.35 V	265W	2.92 Terabits/s	1.81 Teraflops

10.1.1 并行计算机系统结构的分类

1. Flynn分类法

SISD、SIMD、MISD、MIMD

2. MIMD已成为通用多处理机系统结构的选择，原因：

- MIMD具有灵活性；
- MIMD可以充分利用商品化微处理器在性能价格比方面的优势。

计算机机群系统（cluster）是一类广泛被采用的MIMD机器。

多处理机系统是MIMD计算机的一种实现类型，也是目前已经商品化的MIMD的唯一形式。

多处理机系统由多台处理机连接而成，它们能够并行执行独立的程序模块，并且相互通信和同步，以实现作业、任务级的并行。

MIMD计算机与SIMD计算机的主要区别，在于SIMD只能在同一时刻做多件相同的事情，而MIMD却可以在同一时刻做多件相同或不同的事情（多指令流所致），所以求解同一个问题时采用MIMD将能实现更大比例的并行操作，即处理效率更高。

从并行处理的级别看，SIMD是数据级并行处理，流水线是指令级并行处理，MIMD是任务级并行处理。

3. 根据存储器的组织结构，把现有的MIMD机器分为两类：

（每一类代表了一种存储器的结构和互连策略）

- 集中式共享存储器结构
  - 最多由几十个处理器构成。各处理器共享集中式物理存储器。

这类机器有时被称为

SMP机器（Symmetric shared-memory MultiProcessor）.

UMA机器（Uniform Memory Access）

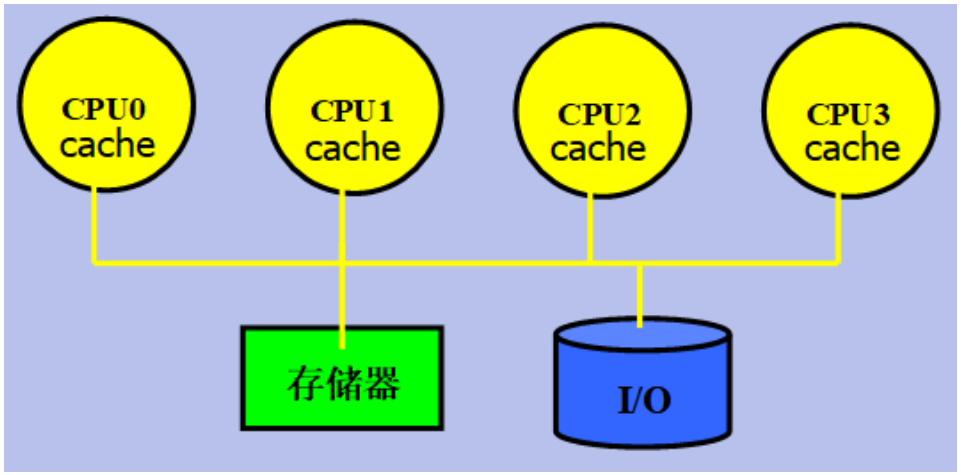

对称式共享存储器多处理机的基本结构

➢ 分布式存储器多处理机

- 存储器在物理上是分布的。 支持较大规模多处理机系统
- 每个结点包含：
  - 处理器,CACHE
  - 存储器
  - I/O
  - 互连网络接口
- 在许多情况下，分布式存储器结构优于集中式共享存储器结构。

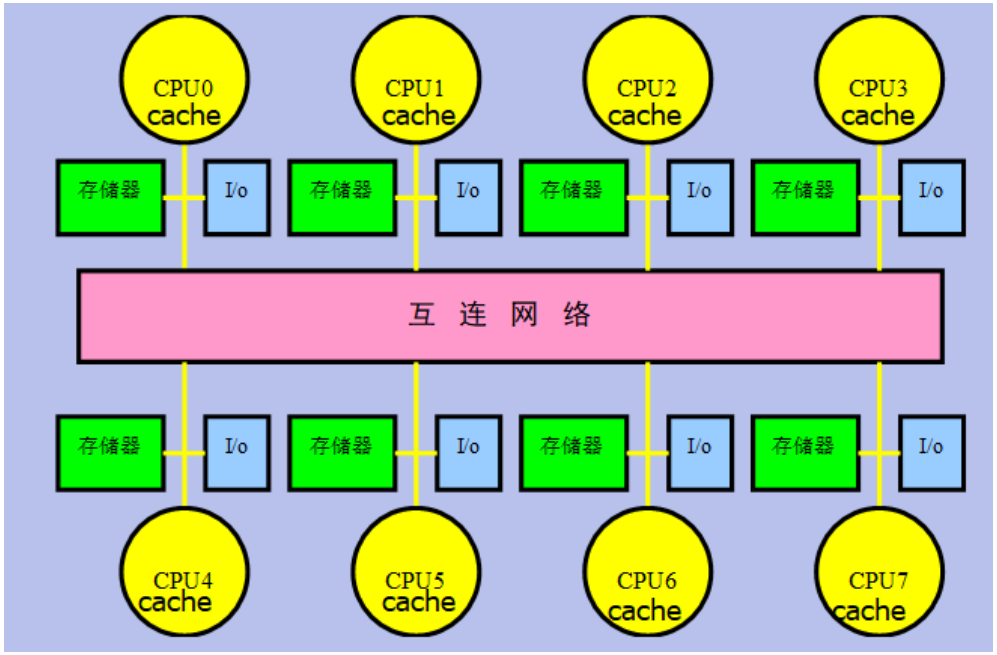

- 将存储器分布到各结点有两个优点
  - 如果大多数的访问是针对本结点的局部存储器，则可降低对存储器和互连网络的带宽要求；
  - 对本地存储器的访问延迟时间小。
- 最主要缺点
  - 处理器间的通信较复杂，且各处理器间访问延迟较大。
- 簇：超级结点
  - 每个结点内包含个数较少（例如2～8）的处理器；
  - 处理器之间可采用另一种互连技术（例如总线）相互连接形成簇。

10.1.2 存储器系统结构和通信机制

1. 两种存储器系统结构

- 共享地址空间

  - 物理上分离的所有存储器作为一个统一的共享逻辑空间进行编址。
  - 任何一个处理器可以访问该共享空间中的任何一个单元（如果它具有访问权），而且不同处理器上的同一个物理地址指向的是同一个存储单元。
  - 这类计算机被称为

  分布式共享存储器系统（DSM: Distributed Shared-Memory）

  NUMA机器（NUMA: Non-Uniform Memory Access）

- 把每个结点中的存储器编址为一个独立地址空间，不同结点中的地址空间是相互独立的。

- 整个系统的地址空间由多个独立的地址空间构成
- 每个结点中的存储器只能由本地处理器访问，远程处理器不能直接对其进行访问。
- 每一个处理器-存储器模块实际上是一台单独计算机
- 现在的这种机器多以集群的形式存在

2. 通信机制

- 共享存储器通信机制
  - 共享地址空间的计算机系统采用
  - 处理器间通过**load/store**指令对相同存储器地址读/写来实现
- 消息传递通信机制
  - 多个独立地址空间的计算机采用
  - 通过处理器间显式地传递消息来完成
  - 消息传递多处理机中，处理器间通过发送消息通信，这些消息请求进行某些操作或者传送数据。

例如：一个处理器要对远程存储器上的数据进行访问或操作：

- 发送消息，请求传递数据或对数据进行操作；

  远程进程调用(RPC， Remote Process Call)

- 目的处理器接收到消息后，执行相应操作或代替远程处理器进行访问，并发送应答消息返回结果。

- **同步消息传递**

  请求处理器发送一个消息后一直要等到应答结果才继续运行。

- **异步消息传递**

  数据发送方知道别处理器需要数据，通信也可从数据发送方开始，数据可不经请求就直接送往数据接受方。

3. 不同通信机制的优点

➢ 共享存储器通信

- 与常用对称式多处理机的通信机制兼容。
- 易于编程，在简化编译器设计方面有优势。
- 采用大家熟悉的共享存储器模型开发应用程序，把重点放到解决对性能影响较大的数据访问上。
- 通信数据量较小时，通信开销较低，带宽利用较好。
- 可通过Cache技术减少远程通信频度，减少通信延迟以及对共享数据访问冲突。

➢ 消息传递通信机制

- 硬件较简单。
- 显式通信，更易搞清何时发生通信以及通信开销是多少。
- 显式通信可让编程者重点注意并行计算的主要通信开销，使之有可能开发出结构更好、性能更高的并行程序。
- 同步很自然地与发送消息相关联，能减少不当同步带来错误的可能性。

10.1.3 并行处理面临的挑战

并行处理面临着两个重要的挑战

- 程序中的并行性有限
- 相对较大的通信开销

$$\text{系统加速比} = \frac{1}{(1-\text{可加速部分比例})+\dfrac{\text{可加速部分比例}}{\text{理论加速比}}}$$

10.1.3 并行处理面临的挑战

多处理机加快运算速度的基本原理是并行计算，即把一个程序分成n等份交给n个处理机同时执行，但在实现上难度较大。主要困难有2个：

(1) 程序中总有一定比例的不可并行部分，如I/O操作；

(2.1) 划分开的各部分之间需要通信（同步、互斥等），分得越细通信越频繁，而单处理机算法中几乎不需通信（即使进程间需通信，时间开销也小到可忽略）；
(2.2) 多处理机分类中的多计算机系统的通信方式是机外传输，每次时间开销比机内传输大成百上千倍。

对算法的要求：
(1) 较高的可并行化比例；
(2) 较低的进程间通信量。

只有满足这2个要求的问题才适合在多处理机系统求解。

1. 第一个挑战

有限的并行性使计算机要达到很高的加速比十分困难。

例10.1 假设想用100个处理器达到80的加速比，求原计算程序中串行部分最多可占多大的比例？

解 Amdahl定律为：

$$\text{加速比}=\frac{1}{\dfrac{\text{可加速部分比例}}{\text{理论加速比}}+(1-\text{可加速部分比例})}$$

$$80=\frac{1}{\dfrac{\text{并行比例}}{100}+(1-\text{并行比例})}$$

由上式可得：并行比例＝0.9975

2. 第二个挑战：多处理机中远程访问的延迟较大

- 在现有机器中，处理器间数据通信约50～1000个时钟周期。
- 主要取决于：

  通信机制、互连网络的种类和机器的规模

- 在几种不同共享存储器并行计算机中远程访问一个字的典型延迟

机器	通信机制	互连网络	处理机最大数量	典型远程存储器访问时间（ns）
Sun Starfire servers	SMP	多总线	64	500
SGI Origin 3000	NUMA	胖超立方体	512	500
Cray T3E	NUMA	3维环网	2048	300
HP V series	SMP	8×8交叉开关	32	1000
HP AlphaServer GS	SMP	开关总线	32	400

例10.2 假设有一台32台处理器的多处理机，对远程存储器访问时间为200ns。除了通信以外，假设所有其它访问均命中局部存储器。当发出一个远程请求时，本处理器挂起。处理器的时钟频率为2GHz，如果指令基本的CPI为0.5（设所有访存均命中Cache），求在没有远程访问的情况下和有0.2%的指令需要远程访问的情况下，前者比后者快多少?

解 有0.2%远程访问的机器的实际CPI为：

CPI＝基本CPI＋远程访问率×远程访问开销

＝0.5＋0.2%×远程访问开销

远程访问开销为：

远程访问时间/时钟周期时间＝200ns/0.5ns＝400个时钟周期

∴ CPI＝0.5＋0.2%×400＝1.3

因此在没有远程访问的情况下机器速度是有0.2%远程访问的机器速度的1.3/0.5=2.6倍。

- 问题的解决
  - 并行性不足： 采用并行性更好的算法
  - 远程访问延迟的降低：靠系统结构支持和编程技术

3. 在并行处理中，影响性能（负载平衡、同步和存储器访问延迟等）的关键因素常依赖于：

应用程序的高层特性

如数据的分配，并行算法的结构以及在空间和时间上对数据的访问模式等。

- 依据应用特点可把多机工作负载大致分成两类：
  - 单个程序在多处理机上的并行工作负载
  - 多个程序在多处理机上的并行工作负载

4. 并行程序的计算 / 通信比率

- 反映并行程序性能的一个重要的度量：

  计算与通信的比率

- 计算 / 通信比率随着处理数据规模的增大而增加；随着处理器数目的增加而减少。

10.2 对称式共享存储器系统结构

- 多个处理器通过共享总线共享一个存储器
- 大容量、多级Cache降低了对内存带宽和总线带宽的要求

  2005，AMD&Intel two processor for server

  2006， Sun T1 eight processpr multicore
- 支持对共享数据和私有数据的Cache缓存

  私有数据供一个单独的处理器使用

  共享数据则是供多个处理器使用
- 共享数据进入Cache产生了一个新的问题

  Cache的一致性问题

10.2.1 多处理机Cache一致性

1. 多处理机的Cache一致性问题

- 允许共享数据进入Cache，就可能出现多个处理器的Cache中都有同一存储块的副本，
- 当其中某个处理器对其Cache中的数据进行修改后，就会使得其Cache中的数据与其他Cache中的数据不一致。

例　由两个处理器（A和B）读写引起的Cache一致性问题

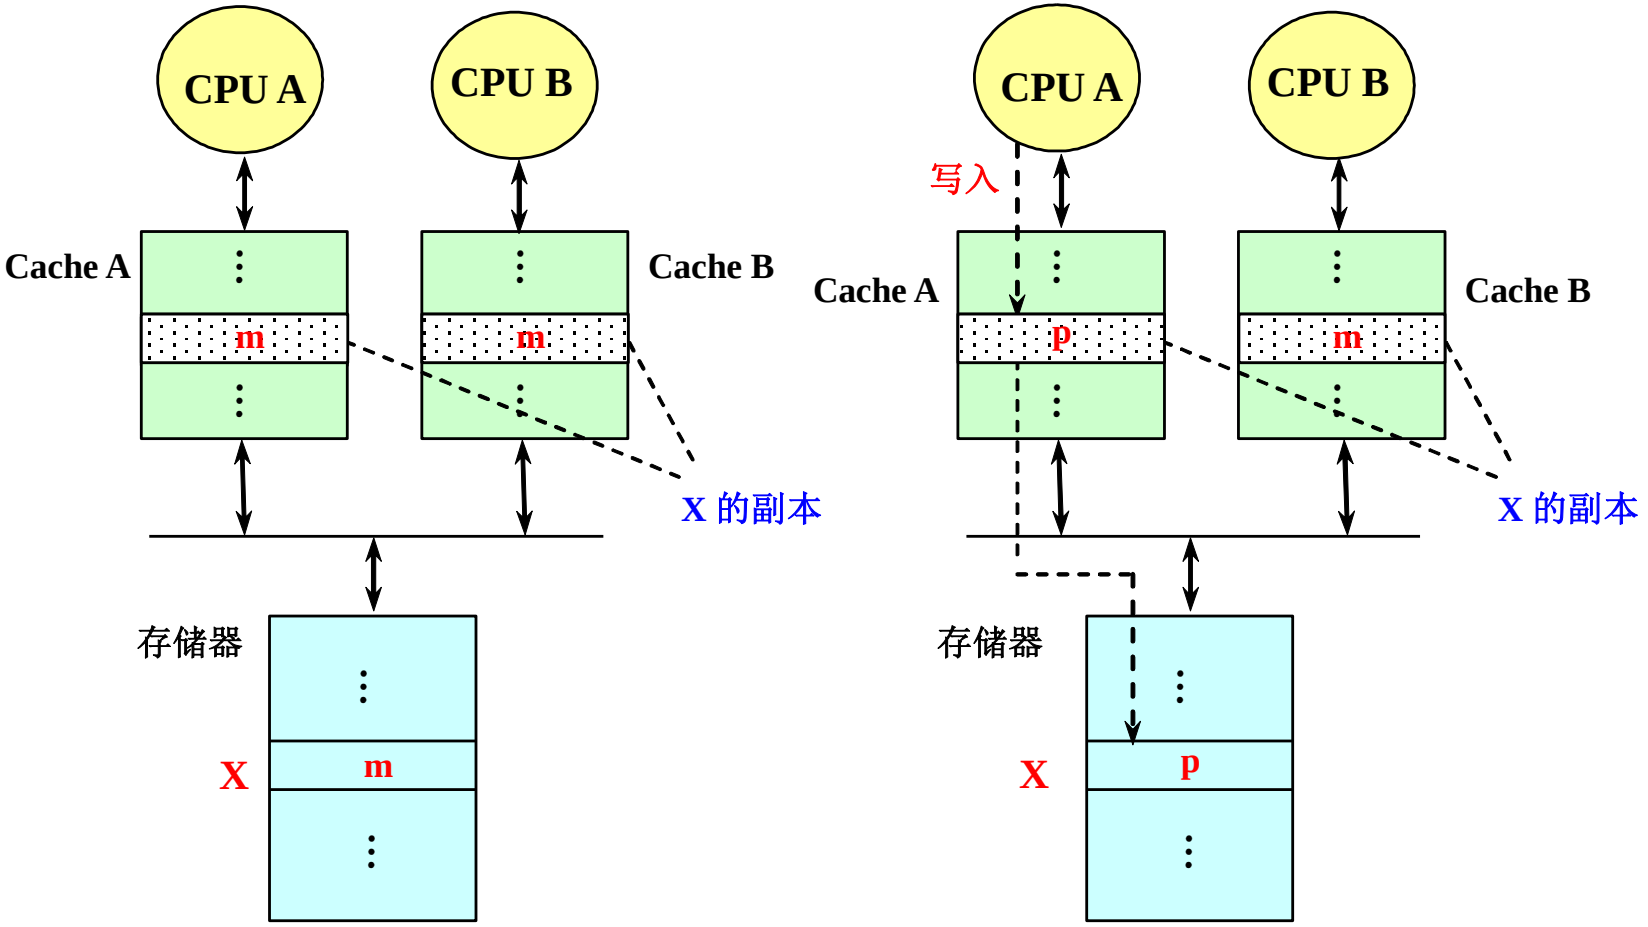

（a） CPU A 写入前

（b） CPU A 将 p 写入 X，p≠m

2. 存储器的一致性

如果对某个数据项的任何读操作均可得到其最新写入的值，则认为这个存储系统是一致的。

- 存储系统行为的两个不同方面
  - What：读操作得到的是什么值
  - When：什么时候才能将已写入的值返回给读操作
- 存储器是一致的，当满足以下条件
  1. 处理器P对单元X进行一次写之后又对单元X进行读，读和写之间没有其它处理器对单元X进行写，则P读到的值总是前面写进去的值。

2. 处理器P对单元X进行写之后，另一处理器Q对单元X进行读，读和写之间无其它写，则Q读到的值应为P写进去的值。
3. 对同一单元的写是串行化的，即任意两个处理器对同一单元的两次写，从各个处理器的角度看来顺序都是相同的。（写串行化 ）

- 在后面的讨论中，我们假设：
  - 直到所有的处理器均看到了写的结果，这个写操作才算完成；
  - 处理器的任何访存均不能改变写的顺序。即允许处理器对读进行重排序，但必须以程序规定的顺序进行写。

10.2.2 实现一致性的基本方案

在一致的多处理机中，Cache提供两种功能：

- 共享数据的迁移

  减少了对远程共享数据的访问延迟，也减少了对共享存储器带宽的要求。

- 共享数据的复制

  不仅减少了访问共享数据的延迟，也减少了访问共享数据所产生的冲突。

一般情况下，小规模多处理机是采用硬件的方法来实现Cache的一致性。

1. Cache一致性协议：在多个处理器中用来维护一致性的协议。
   - 关键：跟踪记录共享数据块的状态
   - 两类协议（采用不同技术跟踪共享数据状态）
     - 监听式协议（snooping）
       - 每个Cache除了包含物理存储器中块的数据拷贝外，也保存着各块的共享状态信息。
       - 所有Cache都可通过某种广播介质访问，所有Cache控制器监听总线来判断它们是否有总线上请求的数据块。
     - 目录式协议（directory）
       - 物理存储器中数据块的共享状态被保存在一个称为目录的地方。开销稍大于前者，但可用于实现更大规模的多处理机。

2. 采用两种方法来解决Cache一致性问题。

- **写作废协议：** 在处理器对某数据项写入之前，保证它拥有对该数据项的唯一访问权。(作废其它的副本)

例 监听总线、写作废协议举例（采用写直达法）

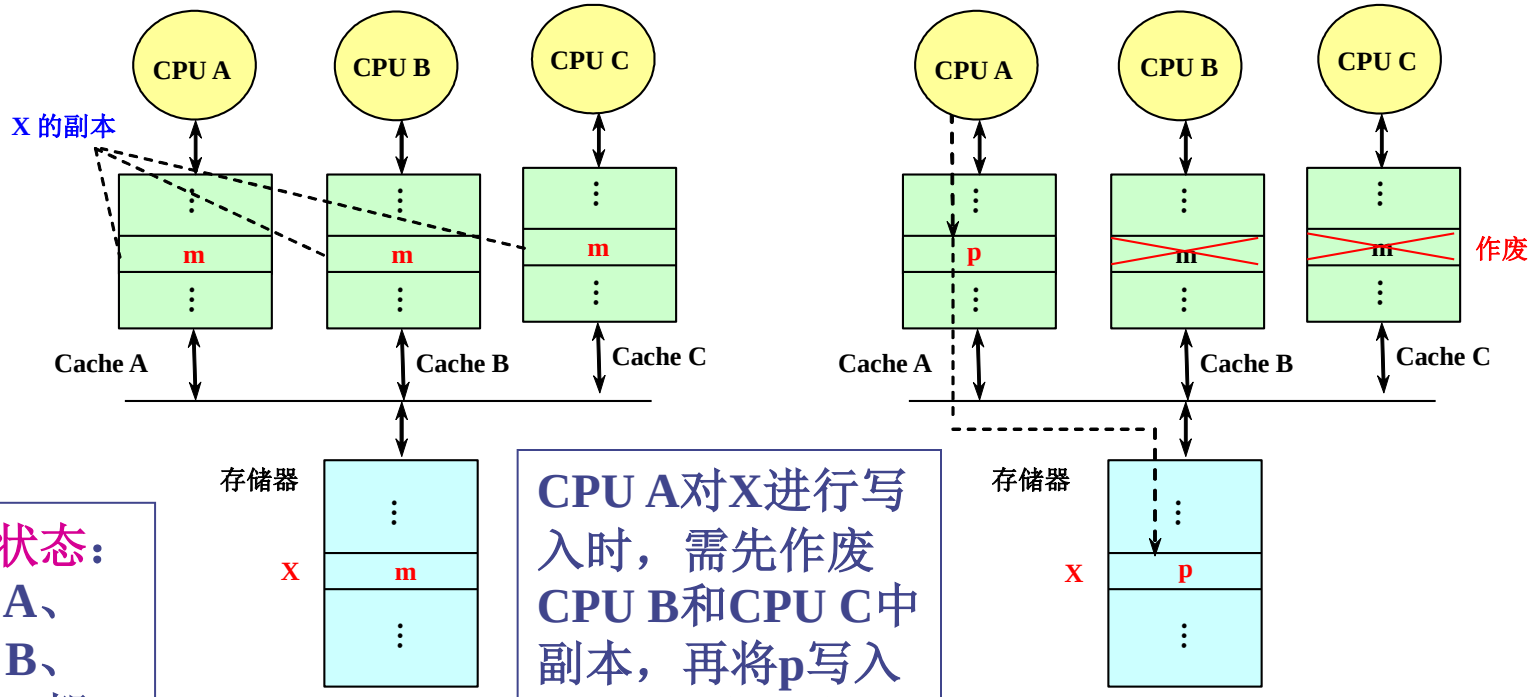

初始状态：CPU A、CPU B、CPU C都有X副本。

CPU A对X进行写入时，需先作废CPU B和CPU C中副本，再将p写入Cache A中副本，同时更新主存单元X。

➢ 写更新协议

当一个处理器对某数据项进行写入时，通过广播使其它Cache中所有对应于该数据项的副本进行更新。

例 监听总线、写更新协议举例（采用写直达法）

假设：3个Cache都有X的副本。

当CPU A将数据p写入Cache A中的副本时，将p广播给所有的Cache，这些Cache用p更新其中的副本。

由于这里是采用写直达法，所以CPU A还要将p写入存储器中的X。如果采用写回法，则不需要写入存储器。

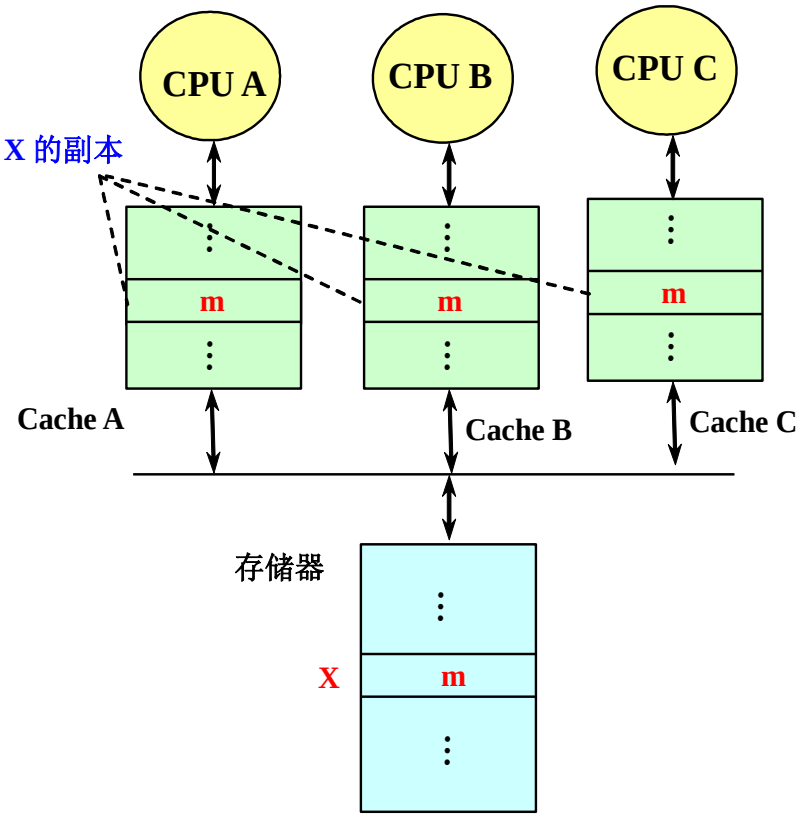

（a） CPU A 写入前

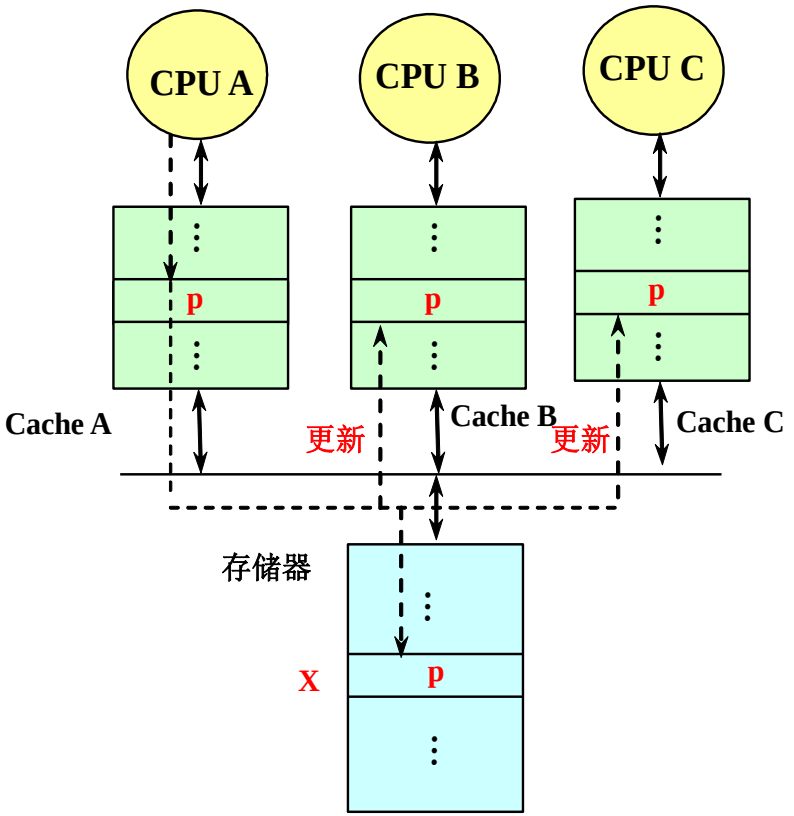

（b） CPU A 将 p 写入 X 后，更新其他 Cache 中的副本

- 写更新和写作废协议性能上的差别主要来自：
  - 在对同一个数据进行多次写操作而中间无读操作时，写更新协议需多次写广播操作，而写作废协议只需一次作废操作。
  - 在对同一Cache块的多个字进行写操作时，写更新协议对于每一个写操作都要进行一次广播，而写作废协议仅在对该块的第一次写时进行作废操作即可。

    写作废是针对Cache块的，写更新则是针对字（或字节）。
  - 考虑从一个处理器A进行写操作后到另一个处理器B能读到该写入数据之间的延迟时间。

    写更新协议的延迟时间较小。
- 后面讲述关注写作废协议

10.2.3 监听协议的实现

1. 监听协议的基本实现技术

- 实现写作废协议的关键：**使用广播介质执行作废**（假定采用的是总线）
  - **当一个处理器Cache响应本地CPU访问时涉及全局操作，Cache控制器需取得总线访问权后，在总线上发相应消息。**
  - **所有处理器都一直在监听总线，检测总线上的地址是否在它们的Cache中。若在，则相应处理。**
- 写操作的串行化：由总线实现

  （获取总线控制权的顺序性）

2. Cache发送到总线上的消息主要有以下两种：

- **RdMiss——读不命中**
- **WtMiss——写不命中**

➢ 需要通过总线找到相应数据块的最新副本，然后调入本地Cache中。

- **写直达Cache：因为所有写入的数据都同时被写回主存，所以从主存中总可以取到其最新值。**
- **写回Cache，得到数据的最新值会困难一些，因为最新值可能在某个Cache中，也可能在主存中。**

（后面的讨论中，只考虑写回法Cache）

- 有的监听协议还增设了Invalidate消息，用来通知其他各处理器作废其Cache中相应的副本。
  - **与WtMiss的区别：Invalidate不引起调块**
- Cache的标识（tag）可直接用来实现监听。
- 修改位—最新副本（写回法）
- 作废一个块只需将其有效位置为无效。
- 给每个Cache块增设一个共享位
  - **为“1”：该块是被多个处理器所共享**
  - **为“0”：仅被某个处理器所独占**

块的拥有者：拥有该数据块的唯一副本的处理器。

3. 监听协议举例

- 在每个结点内嵌入一个有限状态控制器。
  - 该控制器根据来自处理器或总线的请求以及Cache块的状态，做出相应的响应。
- 每个数据块的状态取以下3种状态中的一种：
  - 无效（简称I）：Cache中该块的内容为无效。
  - 共享（简称S）：该块可能处于共享状态。
    - 在多个处理器中都有副本。这些副本都相同，且与存储器中相应的块相同。
  - 已修改（简称M）：该块已经被修改过，并且还没写入存储器。

    （块中的内容是最新的，系统中唯一的最新副本）

下面来讨论在各种情况下监听协议所进行的操作。

- 响应来自处理器的请求
  - 不发生替换的情况

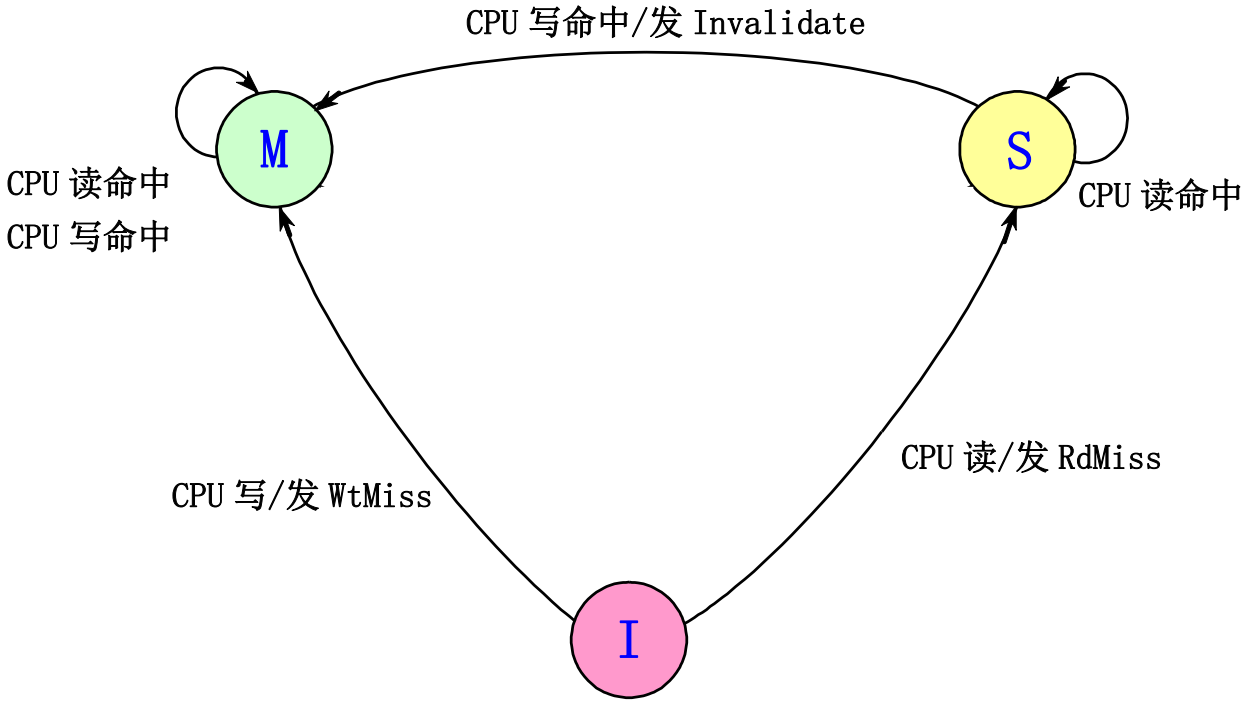

写作废协议中（采用写回法），Cache块的状态转换图

- 发生替换的情况

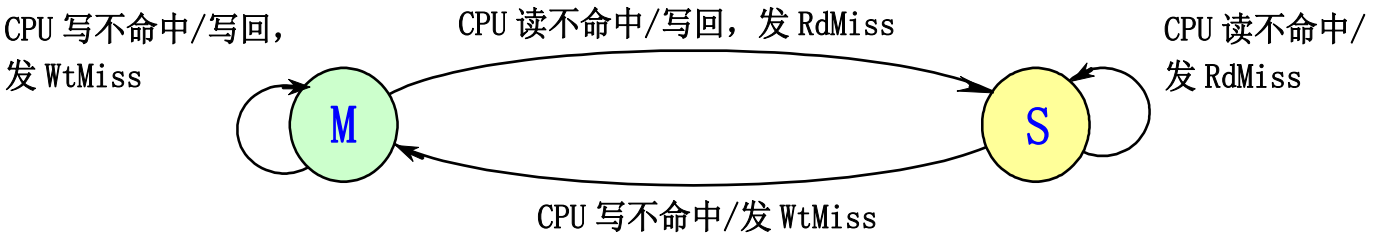

写作废协议中（采用写回法），Cache块的状态转换图

➢ 响应来自总线的请求

- 每个处理器都在监视总线上的消息和地址，当发现有与总线上的地址相匹配的Cache块时，就要根据该块的状态以及总线上的消息，进行相应的处理。

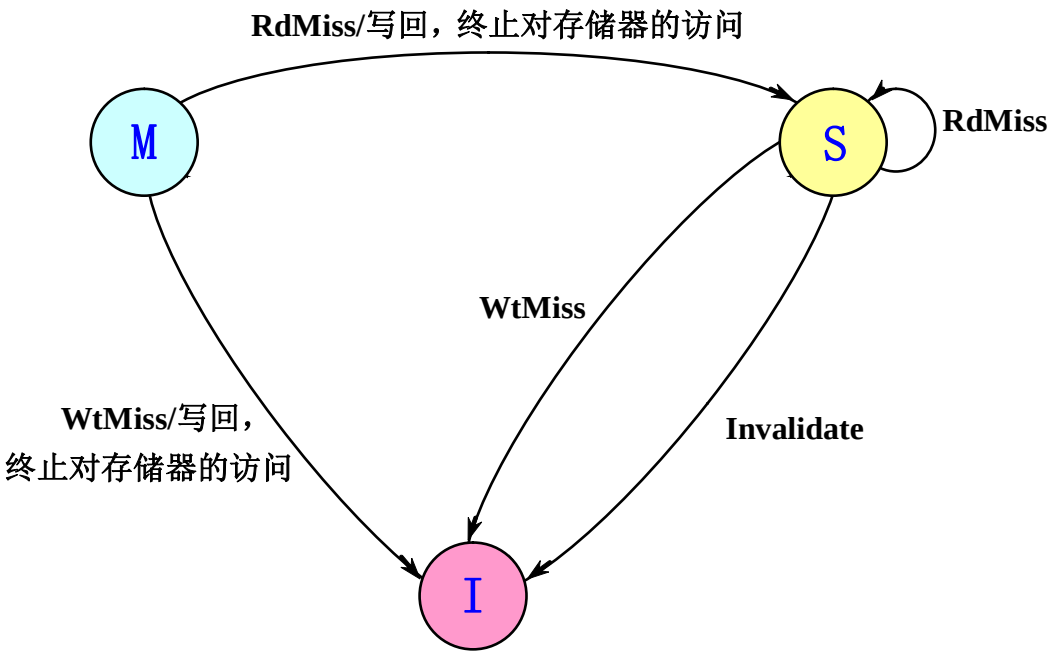

写作废协议中（采用写回法），Cache块的状态转换图

10.3 分布式共享存储器系统结构

10.3.1 目录协议的基本思想

- 广播和监听的机制使得监听一致性协议的可扩放性很差。
- 寻找替代监听协议的一致性协议。

（采用目录协议）

1. 目录协议

- 目录：一种集中的数据结构。对于存储器中的每一个可以调入Cache的数据块，在目录中设置一条目录项，用于记录该块的状态以及哪些Cache中有副本等相关信息。

- 特点：

  对于任何一个数据块，都可以快速地在唯一的一个位置中找到相关的信息。这使一致性协议避免了广播操作。

- 位向量：记录哪些Cache中有副本。
  - 每一位对应于一个处理器。
  - 长度与处理器的个数成正比。
  - 由位向量指定的处理机的集合称为共享集S。
- 分布式目录
  - 目录与存储器一起分布到各结点中，从而对于不同目录内容的访问可以在不同的结点进行。

- 对每个结点增加目录后的分布式存储器多处理机

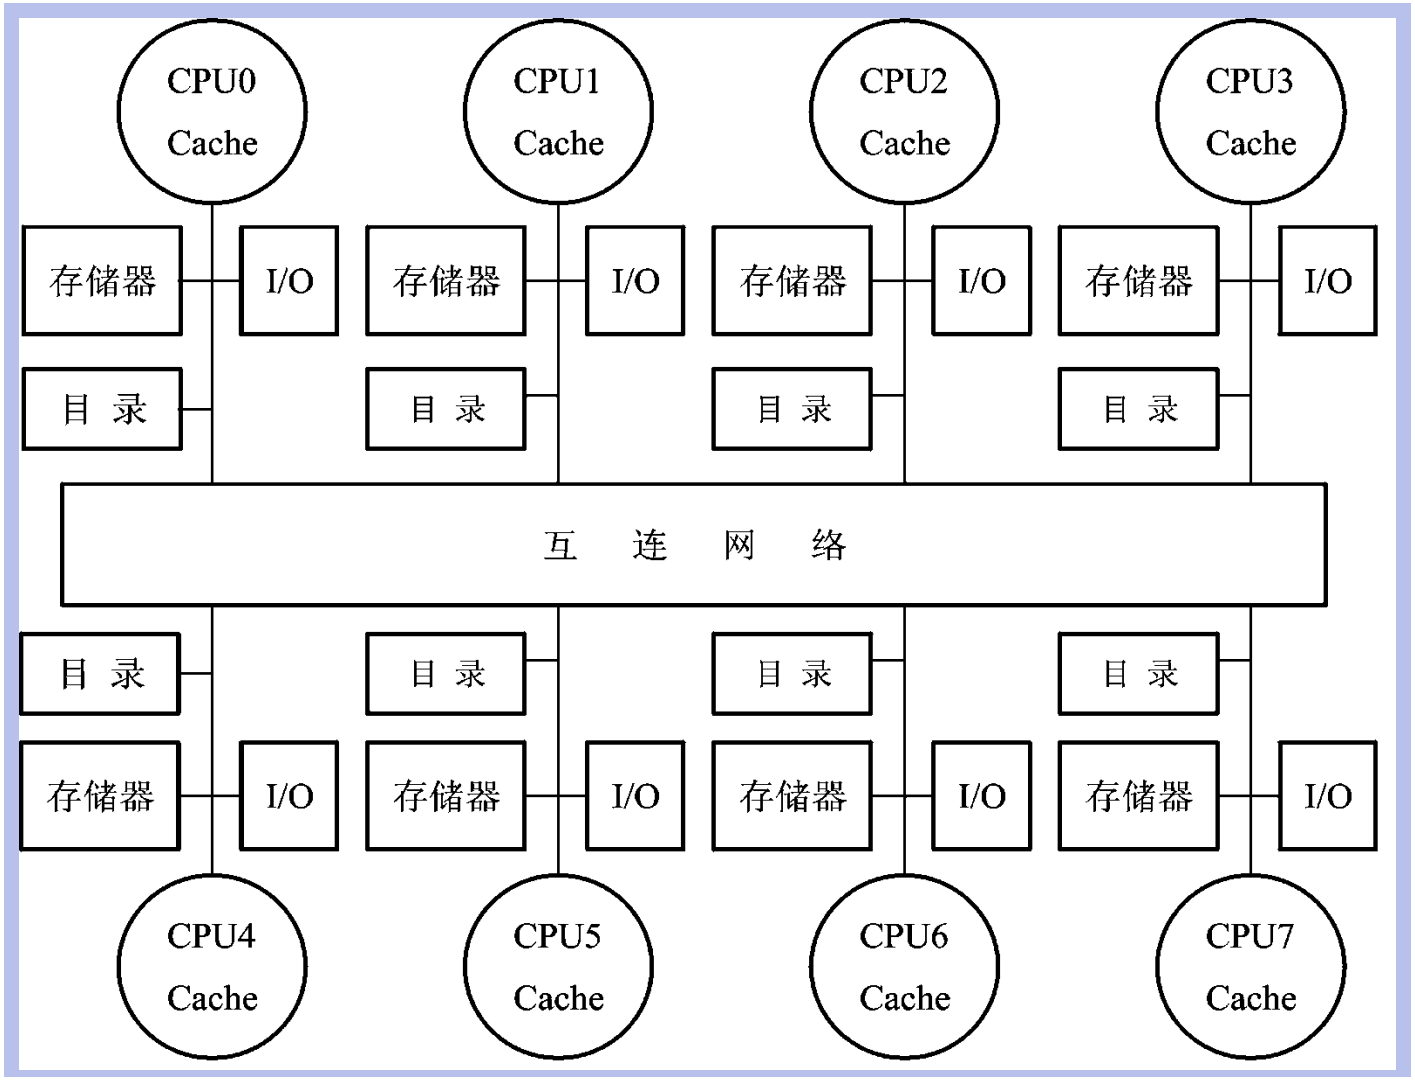

- 目录法最简单的实现方案：对于存储器中每一块都在目录中设置一项。目录中的信息量与M×N成正比。

  其中：

  - M：存储器中存储块的总数量
  - N：处理器的个数
  - 由于M=K×N， K是每个处理机中存储块的数量，所以如果K保持不变，则目录中的信息量就与N^2成正比。

2. 在目录协议中，存储块的状态有3种：

- 未缓冲：该块尚未被调入Cache。所有处理器的Cache中都没有这个块的副本。
- 共享：该块在一个或多个处理机上有这个块的副本，且这些副本与存储器中的该块相同。
- 独占：仅有一个处理机有这个块的副本，且该处理机已经对其进行了写操作，所以其内容是最新的，而存储器中该块的数据已过时。

  这个处理机称为该块的拥有者。

3. 本地结点、宿主结点以及远程结点的关系

- **本地结点：** 发出访问请求的结点
- **宿主结点：** 包含所访问的存储单元及其目录项的结点
- **远程结点：** 包含Cache block的副本。

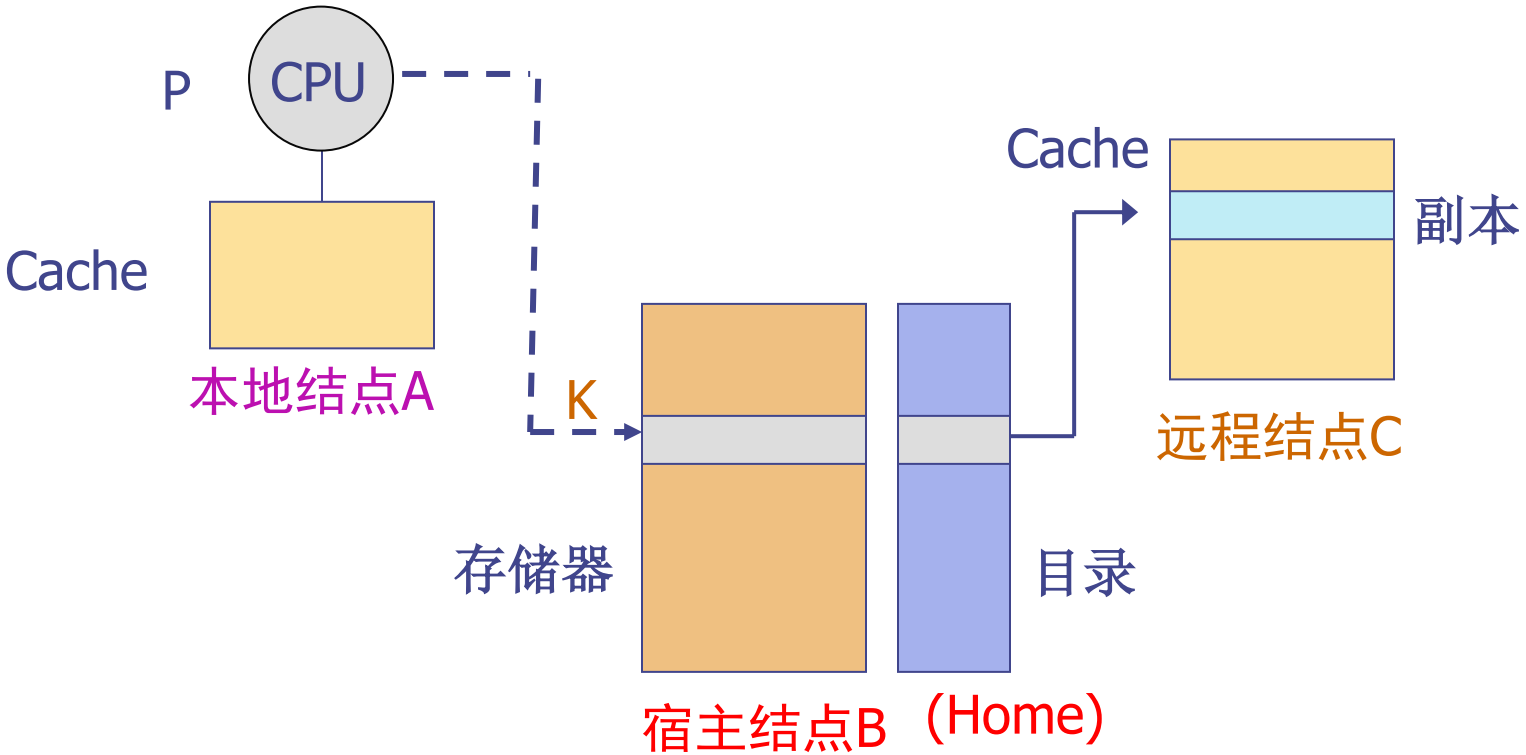

4. 在结点之间发送的消息

- **本地结点发给宿主结点（目录）的消息**

  P：发出请求的处理机编号，K：所要访问的地址

  - **RdMiss（P，K）**

    处理机P读取地址为A的数据时不命中，请求宿主结点提供数据（块），并要求把P加入共享集。

  - **WtMiss（P，K）**

    处理机P对地址A进行写入时不命中，请求宿主结点提供数据，并使P成为所访问数据块的独占者。

  - **Invalidate（K）**

    请求向所有拥有相应数据块副本（包含地址*K*）的远程Cache发Invalidate消息，作废这些副本。

- 宿主结点（目录）发送给远程结点的消息
  - **Invalidate（K）**

    作废远程Cache中包含地址K的数据块。
  - **Fetch（K）**

    从远程Cache中取出包含地址*K*的数据块，并送到宿主结点。把远程Cache中那个块的状态改为“共享”。
  - **Fetch&Inv（K）**

    从远程Cache中取出包含地址K的数据块，并送到宿主结点。然后作废远程Cache中的那个块。

- 宿主结点发送给本地结点的消息
  - **DReply（D）**
    - **D**表示数据内容。
    - 把从宿主存储器获得的数据返回给本地**Cache**。
- 远程结点发送给宿主结点的消息
  - **WtBack（K，D）**
    - 把远程**Cache**中包含地址***K***的数据块写回到宿主结点中， 该消息是远程结点对宿主结点发来的“取数据”或“取/作废”消息的响应。

➢ 本地结点发送给被替换块的宿主结点的消息

- **MdSharer（P，K）**

  用于当本地Cache中需要替换一个包含地址K的块、且该块未被修改过。这个消息发给该块宿主结点，请求它将P从共享集中删除。如果删除后共享集为空，则宿主结点还要将该块状态改为“未缓存”（U）。

- **WtBack2（P，K，D）**

  用于当本地Cache中需要替换一个包含地址K的块、且该块已被修改过。这个消息发给该块宿主结点，完成两步：①写回该块；②进行与MdSharer相同操作。

10.3.2 目录协议实例

- 在基于目录的协议中，目录承担了一致性协议操作主要功能。
  - 本地结点把请求发给宿主结点中的目录，再由目录控制器有选择地向远程结点发出相应消息。
  - 发出的消息会产生两种不同类型动作：
    - 更新目录状态
    - 使远程结点完成相应操作

1. 在基于目录协议的系统中， **Cache块的状态转换图**。

   - 响应本地 CPU请求

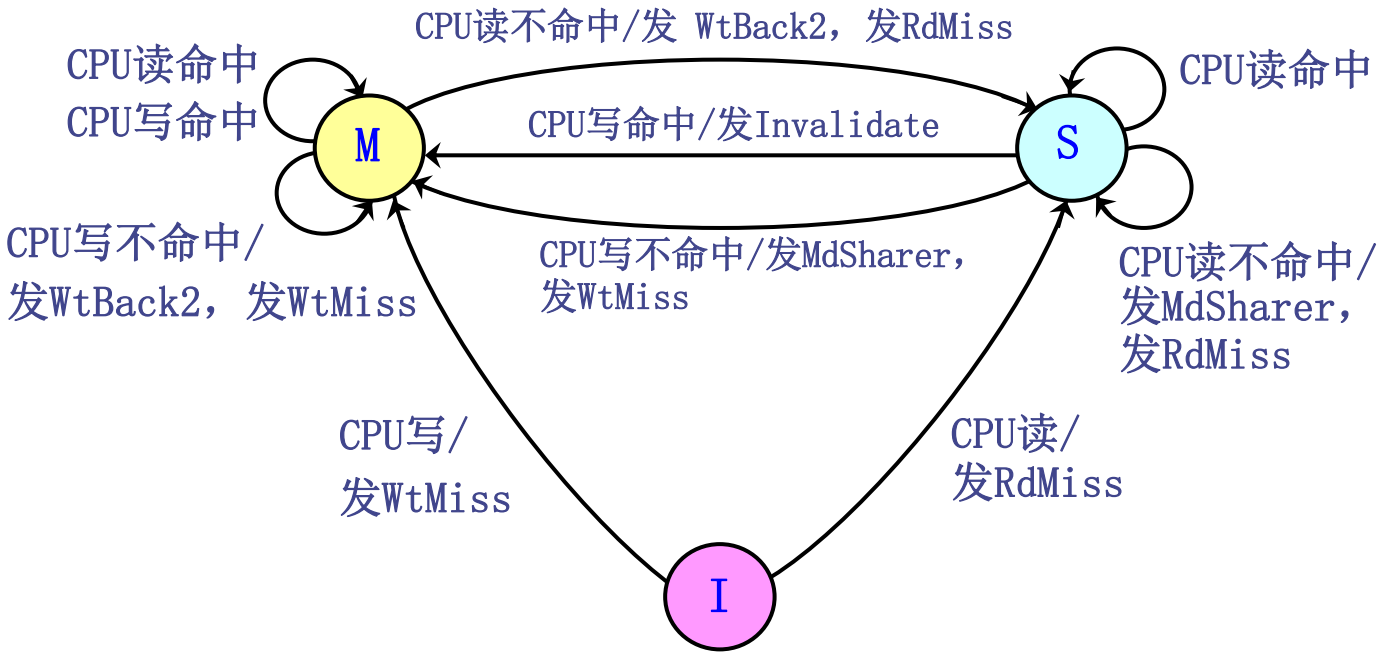

- 远程结点中Cache块响应来自宿主结点请求的状态转换图

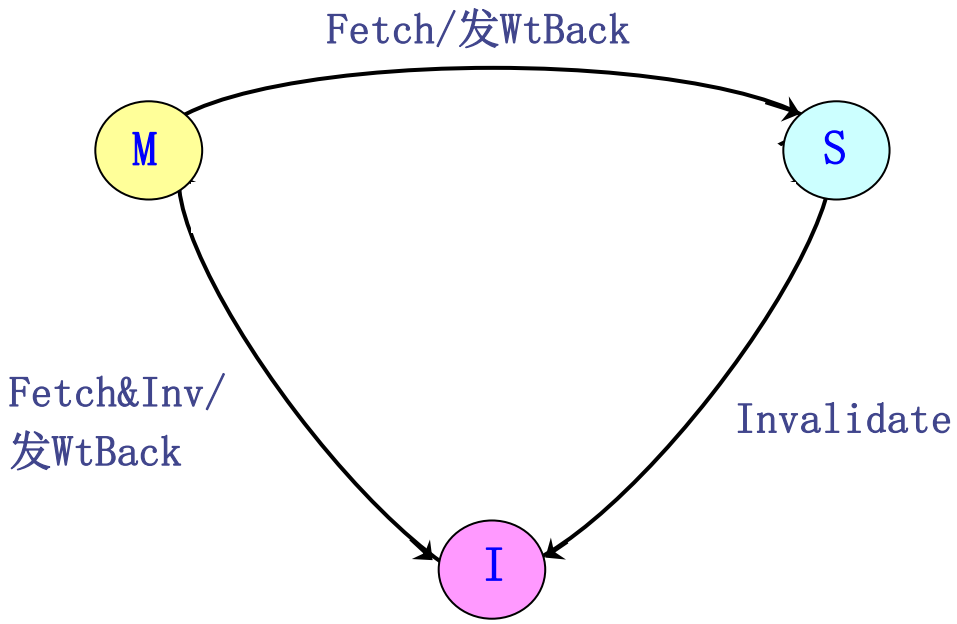

2. 目录的状态转换及相应的操作

- 目录中存储器块的状态有3种
  - 未缓存
  - 共享
  - 独占
- 位向量记录拥有其副本的处理器集合。该集合称为共享集合。
- 对于从本地结点发来的请求，目录所进行的操作包括：
  - 向远程结点发送消息以完成相应的操作。这些远程结点由共享集合指出；
  - 修改目录中该块的状态；
  - 更新共享集合。

- 目录可能接收到3种不同的请求
  - 读不命中
  - 写不命中
  - 数据写回

  （假设这些操作是原子的）

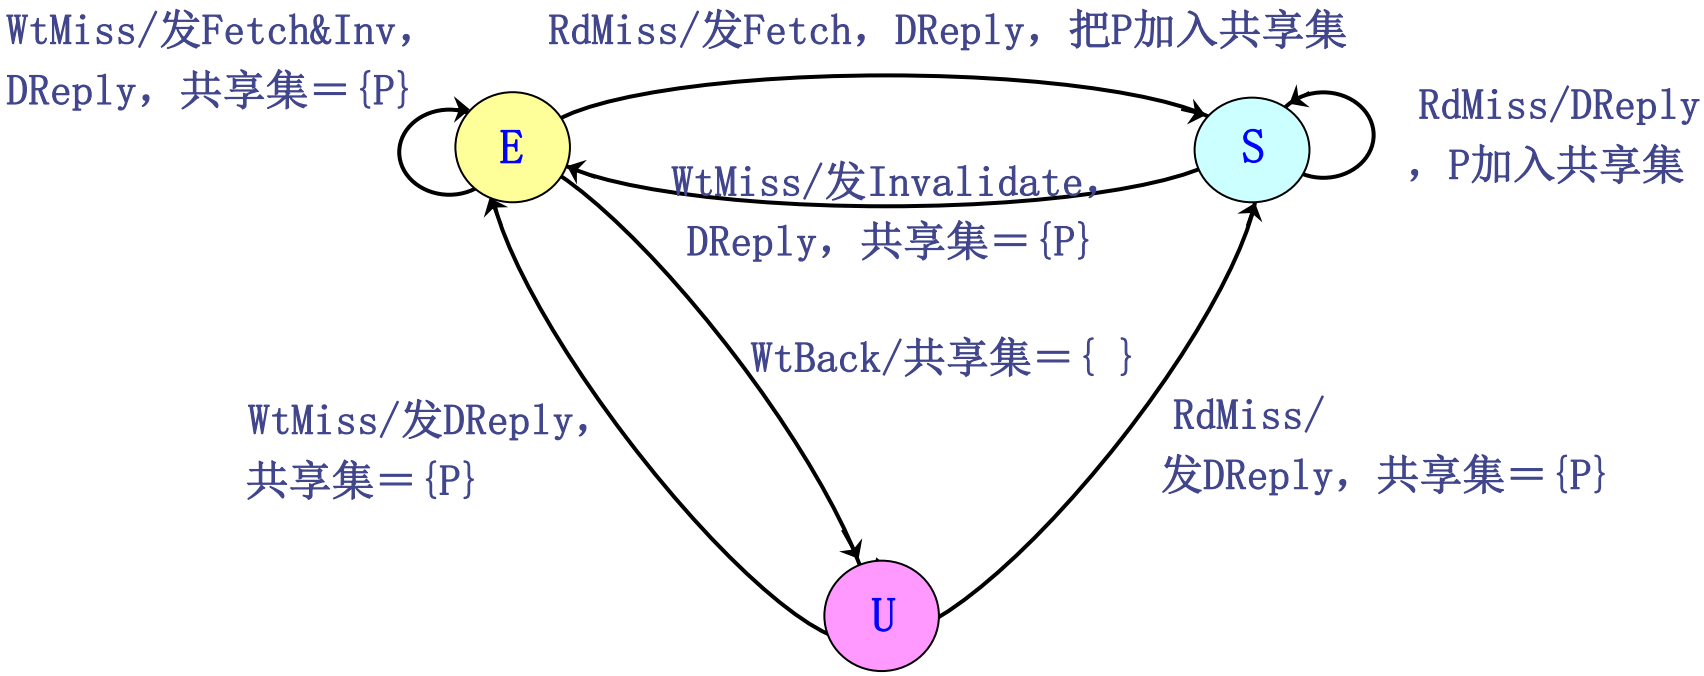

U：未缓存（Uncached）　　S：共享（Shared）：只读

E：独占（Exclusive）：可读写　　P：本地处理器

目录的状态转换及相应的操作

- 当一个块处于未缓存状态时，对该块发出的请求及处理操作为：
  - RdMiss（读不命中）
    - 将所要访问的存储器数据送往请求方处理机，且该处理机成为该块的唯一共享结点，本块的状态变成共享。
  - WtMiss（写不命中）
    - 将所要访问的存储器数据送往请求方处理机，该块的状态变成独占，表示该块仅存在唯一的副本。其共享集合仅包含该处理机，指出该处理机是其拥有者。

- 当一个块处于共享状态时，其在存储器中的数据是当前最新的，对该块发出的请求及其处理操作为：
  - **RdMiss**
    - 将存储器数据送往请求方处理机，并将其加入共享集合。
  - **WtMiss**
    - 将数据送往请求方处理机，对共享集合中所有的处理机发送作废消息，且将共享集合改为仅含有该处理机，该块的状态变为独占。

- 当某块处于独占状态时，该块的最新值保存在共享集合所指出的唯一处理机（拥有者）中。

  有三种可能的请求：

  - **RdMiss**
    - 将“取数据”的消息发往拥有者处理机，将它所返回给宿主结点的数据写入存储器，并进而把该数据送回请求方处理机，将请求方处理机加入共享集合。
    - 此时共享集合中仍保留原拥有者处理机（因为它仍有一个可读的副本）。
    - 将该块的状态变为共享。

- **WtMiss**
  - 该块将有一个新的拥有者。
  - 给旧的拥有者处理机发送消息，要求它将数据块送回宿主结点写入存储器，然后再从该结点送给请求方处理机。
  - 同时还要把旧拥有者处理机中的该块作废。把请求处理机加入共享者集合，使之成为新的拥有者。
  - 该块的状态仍旧是独占。
- **WtBack**（写回）
  - 当一个块的拥有者处理机要从其Cache中把该块替换出去时，必须将该块写回其宿主结点的

存储器中，从而使存储器中相应的块中存放的数据是最新的（宿主结点实际上成为拥有者）；

- 该块的状态变成未缓冲，其共享集合为空。

10.3.3 目录的三种结构

- 不同目录协议的主要区别主要有两个
  - 所设置的存储器块的状态及其个数不同
  - 目录的结构
- 目录协议分为3类

全映象目录、有限映象目录、链式目录

10.4 同 步

重要性：

单处理机的多进程（或多线程）并发只是宏观的，由于处理机的唯一性，不可能“精确地”在某一时间做同一事情。因为CPU时间片切换的不可预测，需防止某一进程（或线程）正在处理、尚未完成的共享资源被切换过去的其它进程（或线程）半途操作，造成双方都不期望结果（如共享打印机）。所以“信号灯”或“锁”的作用是告诉其它进程（或线程）：“此资源尚在处理中”。这种“信号灯”或者“锁”的实现可完全用软件手段。

多处理机的多进程（或多线程）并发则是“真实的”，完全可能“精确地”在某一时刻开始做同一事情，就像多台外设同时申请中断一样。对此，须有专门硬件仲裁与排队同时到达的多个申请，用硬件信号“暂停”未竞争到使用权的处理机。

下面分别讨论用硬件原语实现互斥、同步的基本方法。“原语”意思是该操作具有“原子性”（atomicity），中途不允许其它进程（或线程）插足。原语通常是操作系统提供的一个调用函数。

互斥过程

典型的互斥是临界资源的串行使用。

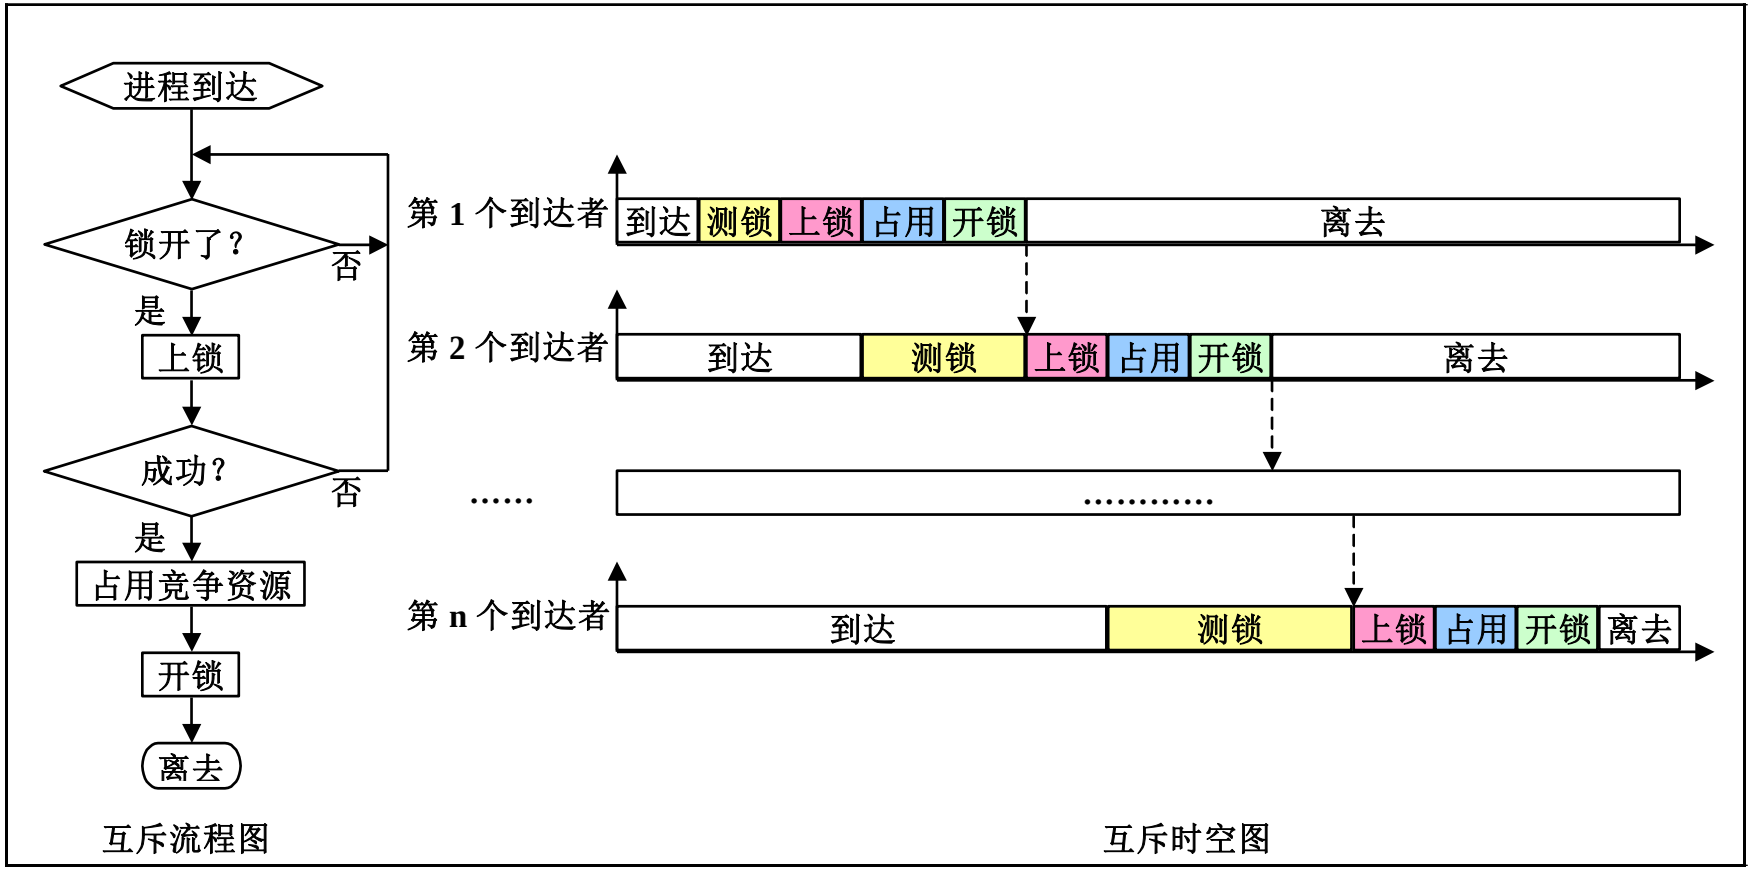

特点：每个进程都需要经历测锁→上锁→开锁的过程，共有n次竞争上锁、n次开锁。只需1个锁变量。

同步过程

典型的同步操作是栅栏（barrier）：栅栏强制所有先到达该栅栏的进程进行等待，直至最后1个进程到达，由它释放全部进程，继续执行。

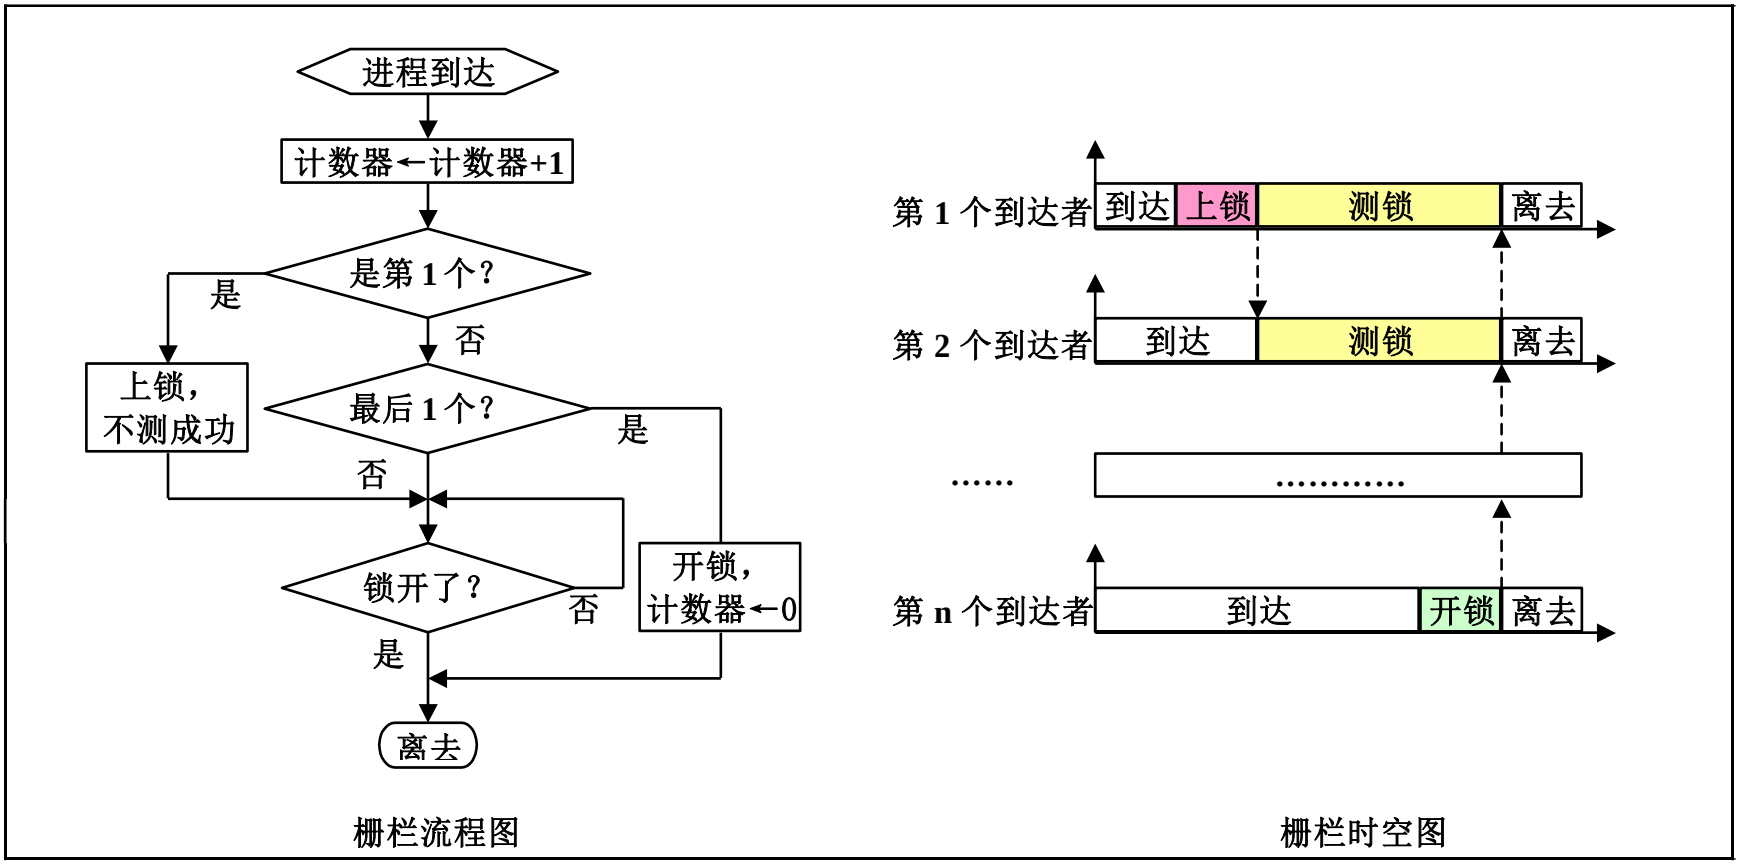

特点：只需1次上锁、1次开锁，n-1个进程需要测锁等待。需2个锁变量。

锁的类型及其操作

[1] 二值锁（布尔锁）

状态：开放、锁闭

操作：读锁、加锁、开锁

用途：互斥，保证临界资源操作的唯一性

[2] 多值锁（算术锁）

状态：负（拒绝）、零（空闲）、正（累积数）

负（欠缺数）、零（空闲）、正（富余数）

操作：读锁、增值、减值、清零

用途：同步，记录等待中的进程数，或已通过的进程数

10.4.0 多处理机的锁存储模型

多处理机系统都用多个局部Cache满足各处理机并行访存的需要，但对进程控制用的信号灯（或称锁）来说，多复本破坏了它们的唯一性，造成同一变量在不同处理机看来有不同值的后果。

因此对信号灯（锁）的管理需遵循以下原则：

①读信号灯在当地Cache进行，只要复件有效；

②写信号灯必须直接作用于主存原件，采用“写直达”策略；

③写过程有排它性，硬件推迟其它处理机的写请求；

④写完原件要通知所有其它Cache中的复件作废，即“一写多废”，让其它处理机随后发生“读失效”或“写失效”；

⑤信号灯管理系统的时间开销主要来源于“读失效”和“写失效”，或称“总线事务处理”次数；

⑥探讨不同的锁管理机制，目的是在程序正确前提下，减少时间开销。

10.4 同 步

同步机制通常是在硬件提供的同步指令的基础上，通过用户级软件例程来建立的。(Lock & Unlock)

10.4.1 基本硬件原语

在多处理机中实现同步，所需的主要功能是：

- 一组能以原子操作的方式读出并修改存储单元的硬件原语。它们都能以原子操作的方式读/修改存储单元，并指出所进行的操作是否以原子的方式进行。
- 通常情况下，用户不直接使用基本的硬件原语，原语主要供系统程序员用来编制同步库函数。

1. 典型操作：原子交换EXCH（atomic exchange）

功能：将一个存储单元的值和一个寄存器的值进行交换。建立一个锁，锁值：

- 0：表示开的（可用）
- 1：表示已上锁（不可用）

➢ 处理器上锁时，将**对应于该锁的存储单元的值**与存放在某寄存器中的1进行交换。

- 如果返回值为1，别的处理器已经上了锁
- 如果返回值为0，存储单元的值此时已置换为1，防止了别的进程竞争该锁

➢ 实现同步的关键：交换操作的**原子性**

2. 测试并置定（test_and_set）
   - 先测试一个存储单元的值，如果符合条件则修改其值。
3. **读取并加1（fetch_and_increment）**
   - 它返回存储单元的值并自动增加该值。

4. 使用指令对

- LL(load linked或load locked)
- SC(store conditional)

➢ 指令顺序执行：

- 如果由LL指明的存储单元的内容在SC对其进行写之前已被其它指令改写过，则第二条指令SC执行失败；
- 如果在两条指令间进行切换也会导致SC执行失败。

➢ SC将返回一个值来指出该指令操作是否成功：

- “1”：成功
- “0”：不成功

➢ LL则返回该存储单元初始值。

4、LL/SC指令对（一种比较容易实现的原语，可等价替代其它原语）

- LL(load linked或load locked)是一条特殊读指令，它读取“锁”单元原值到指定寄存器。注意该指令通常只访问Cache；
- SC(store conditional)是一条特殊写指令，它首先再读“锁”单元，如果与LL所读相同，则将指定寄存器中的新值送给“锁”单元，并返回值1表示成功。如果内容不同，直接返回 0表示失败。
- 语法：见下例。

例A：用LL/SC指令实现原子交换R4与R1所致单元值的交换。

```
try：OR  R3, R4, R0     ; R3←R4（R4是要换入锁的值）
     LL  R2, 0(R1)      ; R2←0(R1)（存储单元中的锁值）
     SC  R3, 0(R1)      ; 若写之前0(R1)的值未变，则写入成功，返回1
     BEQZ  R3, try      ; 返回0表示写失败，再试
     MOV  R4, R2        ; 从锁中换出的值交给R4（应写成OR  R4, R2, R0）
```

- **LL/SC机制的一个优点：用来构造别的同步原语**

例B：用LL/SC指令实现 fetch_and_increment

```
try：LL  R2, 0(R1)          ; R2←0(R1)
     DADDIU  R2, R2, #1 ; R2←R2 +1
     SC  R2, 0(R1)           ; 0(R1)←R2
     BEQZ  R2, try           ; 如不成功，再试
```

10.4.2 用一致性实现锁

- 采用多处理机的一致性机制来实现旋转锁。
- 旋转锁

  处理器环绕一个锁不停地请求获得该锁。适合于这样的场合：锁被占用的时间很少，在获得锁后加锁过程延迟很小。

旋转锁（又称自旋锁，Spin Lock）

定义：该系统函数循环读取、判断指定的锁变量，直至发现锁被释放，然后上锁，返回用户程序。

释放锁的时候，只需简单地将锁置为0 。

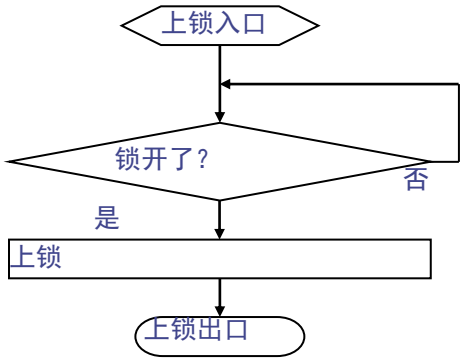

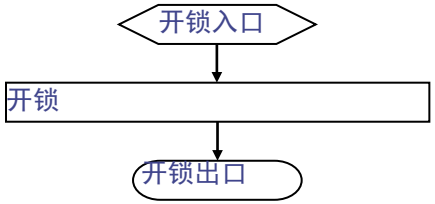

语法：spin（slock=0）

锁值：教材P320倒12行用置0来释放锁，而linux内核规定slock=1代表锁被释放，0或负值代表锁被占用。《题解》P234倒8行置1来释放锁，显然又用了linux内核规定。为便于看书，我们先遵守教材规定。

功能：等同于原语“测试并置定”

1. 无Cache一致性机制

在存储器中保存锁变量，处理器可以不断地通过一个原子操作请求使用权。

比如：利用原子交换操作，并通过测试返回值而知道锁的使用情况。释放锁的时候，处理器只需简单地将锁置为0。

例：用原子交换操作对旋转锁进行加锁，R1中存放该旋转锁地址。

```
        DADDIU  R2, R0, #1 ; R2←1
lockit: EXCH    R2, 0(R1)  ; R2 ←交换→ 0(R1)
        BNEZ    R2, lockit ; 如R2≠0，再试
```

2. 机器支持Cache一致性

- 将锁调入Cache，并通过一致性机制使锁值保持一致。
- 优点：
  - 可使“环绕”的进程只对本地Cache中的锁（副本）进行操作，而不用在每次请求占用锁时都进行一次全局的存储器访问；
  - 可利用访问锁时所具有的局部性，即处理器最近使用过的锁不久又会使用。

（减少为获得锁而花费的时间）

- 改进旋转锁（获得第一条好处，避免写操作）
  - 只对本地Cache中锁的副本进行读取和检测，直到发现该锁已经被释放。然后，该程序立即进行交换操作，去跟在其它处理器上的进程争用该锁变量。
  - 修改旋转锁程序

```
lockit：LD   R2, 0(R1)          ; R2←0(R1)
        BNEZ  R2, lockit        ; 如R2≠0，再读
        DADDIU  R2, R0, #1      ; R2←1
        EXCH  R2, 0(R1)         ; R2 ←交换→ 0(R1)
        BNEZ  R2, lockit        ; 如R2≠0，再试
```

每次EXCH都要写主存，而LD指令只访问Cache。改进后仅当“锁”=0时再使用EXCH，可减少与其它处理器的访存冲突

3个处理器利用原子交换争用旋转锁所进行的操作

步骤	处理器P0	处理器P1	处理器P2	锁的状态	总线/目录操作
1	占有锁	环绕测试 是否lock=0	环绕测试 是否lock=0	共享	无
2	将锁置为0	（收到作废命令）	（收到作废命令）	专有（P0）	P0发出对锁变量的作废消息
3		Cache不命中	Cache不命中	共享	总线/目录收到P2 Cache不命中；锁从P0写回
4		（因总线/目录忙而等待）	lock=0	共享	P2 Cache不命中被处理
5		Lock=0	执行交换， 导致Cache不命中	共享	P1 Cache不命中被处理
6		执行交换， 导致Cache不命中	交换完毕：返回0 并置lock=1	专有（P2）	总线/目录收到P2 Cache不命中；发作废消息
7		交换完毕： 返回1	进入关键程序段	专有（P1）	总线/目录处理P1 Cache不命中；写回
8		环绕测试 是否lock=0			无

- LL / SC原语另一个优点：读写操作明显分开，LL不产生总线数据传送。这使下面代码与使用经过优化交换的代码具有相同特点：

例：用LL/SC指令实现旋转锁

```
lockit：LL  R2, 0(R1)          ; R2←0(R1)
        BNEZ  R2, lockit       ; 如R2≠0，再读
        DADDIU  R2, R0, #1 ; R2←1
        SC  R2, 0(R1)          ; 0(R1)←R2
        BEQZ  R2, lockit       ; 如不成功，再试
```

第一个分支形成环绕的循环体，第二个分支解决了两个处理器同时看到锁可用的情况下的争用问题。尽管旋转锁机制简单并且具有吸引力，但难以将它应用于处理器数很多的情况。

10.4.3 同步性能问题

简单旋转锁不能很好地适应可缩扩性。大规模多处理机中，若所有的处理器都同时争用同一个锁，则会导致大量的争用和通信开销。

10.4.3 同步操作的性能问题（P322）

尽管具有使用简单方便、性能好的优点，旋转锁也存在自身的不足：

(1) 由于旋转锁的无序竞争，可能造成等待时间延长，并且存在“不公平”问题。原因有2。

a. 随着处理器个数的不断增加，旋转锁竞争性操作增加了系统负担，从而导致更长的等待时间；

b. 一个处理器释放旋转锁时要通知等待中的所有处理器，将Cache复本作废，那么几何距离上邻近它的处理器可能会较先地更新Cache，因而增大获得旋转锁的机率。

(2) 由于每个申请旋转锁的处理器均在全局变量 **slock** 上忙等待，系统总线将因为处理器间的Cache同步而导致繁重的流量（即因读失效或写失效引起的Cache调入、调出），从而降低了系统整体的性能。

例10.3 假设某条总线上有10个处理器同时准备对同一变量加锁。如果每个总线事务处理（读不命中或写不命中）的时间是100个时钟周期，而且忽略对已调入Cache中的锁进行读写的时间以及占用该锁的时间。

（1）假设该锁在时间为0时被释放，并且所有处理器都在旋转等待该锁。问：所有10个处理器都获得该锁所需的总线事务数目是多少？

（2）假设总线是非常公平的，在处理新请求之前，要先全部处理好已有的请求。并且各处理器的速度相同。问：处理10个请求大概需要多少时间？

解 当i个处理器争用锁的时候，它们都各自完成以下操作序列，每一个操作产生一个总线事务：

- 访问该锁的i个LL指令操作
- 试图占用该锁（并上锁）的i个SC指令操作
- 1个释放锁的存操作指令

因此对于i个处理器来说，一个处理器获得该锁所要进行的总线事务的个数为2i+1。

由此可知，对n个处理器，总的总线事务个数为：

$$\sum_{i=1}^{n}(2i+1)=n(n+1)+n=n^2+2n$$

对于10个处理器来说，其总线事务数为120个，需要12000个时钟周期。

例10.3（续1）

解：

此题应根据由LL/SC指令实现的旋转锁工作过程分析，题目要求不清。解法可以从推导任意n个处理器的公式入手。

1. **开始时，n个处理器竞争，n个Cache中都没锁复本，所以它们的LL操作会导致n个读失效，产生n个读主存的总线事务，分别将锁变量调入n个Cache；**
2. **动作最快的1个处理机抢先完成SC操作，它把主存中的锁原件“加锁”了，用了1个写主存的总线事务，随即通知其余n-1个Cache复本作废，其余n-1个SC操作都发生写失效或者读失效（视作废通知是在SC读之前到达还是读之后到达），需要n-1个读主存的总线事务重新调入Cache（“按写分配”策略，因为随后还要多次读Cache），合计n个总线事务；**
3. **“加锁”成功的那个处理机对临界资源使用期间，其余n-1个处理器只是循环对各自Cache做LL读，并无总线事务发生。最后成功者需要“开锁”，又用了1个写主存的总线事务，并再次通知其余n-1个Cache复本作废。**

这样总共有2n+1个总线事务；

由于收到通知的n-1个Cache复件作废，对应n-1个处理器的LL操作立即产生读失效，又重演刚才n个处理器竞争的过程，只是参与者下降到n-1个，……。

依此类推，当最后1个处理器将锁释放后，前后发生的总线事务次数共有

$$[2n+1]+[2(n-1)+1]+.....+[2+1]=\sum_{i=1}^{n}(2i+1)=n(n+1)+n=n^2+2n$$

本题中n=10，总线事务数共有120个，每个总线事务花费100个时钟周期，合计需要12000个时钟周期。

- 本例中问题的根源：锁的争用、对锁进行访问的串行性以及总线访问的延迟。
- 旋转锁的主要优点：总线开销或网络开销比较低，而且当一个锁被同一个处理器重用时具有很好的性能。

1. 如何用旋转锁来实现一个常用的高级同步原语：栅栏
   - 栅栏强制所有到达该栅栏的进程进行等待，直到全部的进程到达栅栏，然后释放全部的进程，从而形成同步。

- 栅栏的典型实现

  用两个旋转锁：

  - 用来保护一个计数器，它记录已到达该栅栏的进程数；
  - 用来封锁进程直至最后一个进程到达该栅栏。

- 一种典型的实现,其中：

  - lock和unlock提供基本的旋转锁
  - 变量count记录已到达栅栏的进程数
  - total规定了要到达栅栏的进程总数
  - 对counterlock加锁保证增量操作的原子性。
  - release用来封锁进程直到最后一个进程到达栅栏。
  - spin（release=1）使进程等待直到全部的进程到达栅栏。

```
lock (counterlock) ;                    //  确保更新的原子性
    if (count= =0) release=0;    //  第一个进程则重置release
    count=count+1;                      //  到达进程数加1
unlock (counterlock) ;                  //  释放锁
    if (count= =total) {                //  进程全部到达
        count=0;                        //  重置计数器
        release=1;                      //  释放进程
        }
    else {                              //  还有进程未到达
        spin (release=1) ;              //  等待别的进程到达
        }
```

- 实际情况中会出现的问题

  栅栏通常是在循环中使用，从栅栏释放的进程运行一段后又会再次返回栅栏，这样有可能出现某个进程永远离不开栅栏的状况(它停在旋转操作上)。

  - 一种解决方法

    当进程离开栅栏时进行计数（和到达时一样），在上次栅栏使用中的所有进程离开之前，不允许任何进程重用并初始化本栅栏。但这会明显增加栅栏的延迟和竞争。

- 另一种解决办法
  - 采用sense_reversing栅栏，每个进程均使用一个私有变量local_sense，该变量初始化为1。
  - sense_reversing栅栏的代码

优缺点：使用安全，但性能比较差。

对于10个处理器来说，当同时进行栅栏操作时，如果忽略对Cache的访问时间以及其它非同步操作所需的时间，则其总线事务数为204个，如果每个总线事物需要100个时钟周期，则总共需要20400个时钟周期。

```
local_sense=! local_sense;          //  local-sense取反
    lock (counterlock) ;            //  确保更新的原子性
    count++;                        //  到达进程数加1
    unlock (counterlock) ;          //  释放锁
    if (count= =total) {            //  进程全部到达
        count=0;                    //  重置计数器
        release=local_sense;        //  释放进程
        }
    else {                          //  还有进程未到达
        spin (release==local_sense) ; //  等待信号
        }
```

例10.4（教材2版例7.4） 假设总线上10个处理器同时执行一个栅栏，设每个总线事务需100个时钟周期，忽略Cache块中锁的读、写实际花费的时间，以及栅栏实现中非同步操作的时间，计算10个处理器全部到达栅栏，被释放及离开栅栏所需的总线事务数。设总线完全公平，整个过程需多长时间?

答：下表给出一个处理器通过栅栏发出的事件序列，设第一个获得总线的进程并未拥有锁。

表 10.11 第 i 个处理器通过栅栏产生的事件序列

事件	数量	对应源代码	说明
LL	i	Lock(counterlock)；	所有处理器抢锁
SC	i	Lock(counterlock)；	所有处理器抢锁
LD	1	count=count+1；	一个成功
LL	i-1	Lock(counterlock)；	不成功的处理器再次抢锁
SD	1	count=count+1；	获得专有访问产生的失效
SD	1	unlock(counterlock)；	获得锁产生的失效
LD	2	spin(release=local_sense)；	读释放：初次和最后写产生的失效

对第i个处理器，总线事务数为3i+4，而最后一个到达栅栏的处理器需要的事务数少一个，因此n个处理器所需的总线事务数为

$$[3n+4]+[3(n-1)+4]+.....+[3+1]-1=\sum_{i=1}^{n}(3i+4)-1=(3n^2+11n)/2-1$$

对于10个处理器来说，共需要204个总线事务，如果每个总线事物需要100个时钟周期，则总共需要20400个时钟周期，大约为互斥问题的2倍。

2. 当竞争不激烈且同步操作较少时，我们主要关心的是一个同步原语操作的延迟。
   - 即单个进程要花多长时间才完成一个同步操作。
   - 基本的旋转锁操作可在两个总线周期内完成：
     - 一个读锁
     - 一个写锁

     我们可用多种方法改进，使它在单个周期内完成操作。
3. 同步操作最严重的问题：进程进行同步操作的串行化。它大幅度地增加了完成同步操作所需要的时间。

Homework:

1. 10.6、

10.9 假设总线上有**10**个处理器，同时开始执行简单栅栏同步（不考虑混淆“同步”问题），此时“计数器”**count=0**、“到齐锁”**release=0**（关）。每个总线事务处理（即内存访问）的时间是**100**个时钟周期，忽略对已调入**Cache**中的锁进行读写的时间，以及栅栏实现中非同步操作的时间。计算它们全部通过栅栏所需的总线事务数，以及折算的时钟周期数。要求

(1) 栅栏采用旋转锁实现（用**LL/SC**指令对实现旋转锁）；

(2) 栅栏采用排队锁实现；

(3) 栅栏采用**fetch_and_increment**原语实现。

用读取并加1实现栅栏同步1

原语Fetch_and_increment可以原子地取值并增量，减少栅栏记数时所需的时间，从而减小瓶颈的串行度， 改进栅栏的实现。

例10.5（教材2版例7.6）：写出fetch_and_increment栅栏的代码。条件与前面假设相同，并设一次fetch_and_increment操作也需100个时钟周期。计算10个处理器通过栅栏的时间，以及所需的总线周期数。

用读取并加1实现栅栏同步2

解 下面的程序段给出栅栏的代码。对n个处理器，这种实现需要进行n次fetch_and_increment操作，访问count变量的n次cache失效和释放时的n次Cache失效，这样总共需要3n个总线事务。对10个处理器，总共需要30个总线事务或3000个时钟周期。这里如同排队锁那样，时间与处理器个数成线性增长。

```
local_sense = ! local_sense;          /*local_sense变反*/
fetch_and_increment(count);            /*原子性更新*/
if(count==total){                      /*进程全部到达*/
        count=0;                       /*初始化计数器*/
        release=local_sense;           /*释放进程*/
        }
else    {                              /*还有进程未到达*/
        spin(releaze=local_sense);     /*等待信号*/
        }
```

从上述例子看出，当处理器个数很多时，花费在锁竞争上的时间开销非常大，而如果不竞争，按事先安排的次序互斥地使用临界资源，10个处理器的加锁、解锁动作仅需要20个总线事务。排队锁的想法就是由此产生的。

排队锁的基本原理是用一个数组记录各个进程申请锁的先后顺序，当一个进程释放锁以后，只从队列中取出等在最前面的下一个进程，避免了重新竞争的大量时间开销与“公平性”问题。

排队锁的具体实现算法有很多种，在不同应用中的名称也不一样。比如在Windows中被称为“排队自旋锁”（Queued Spinlock），在Linux内核2.6.25版中也叫“排队自旋锁”，英文则是FIFO Ticket Spinlock。

- **硬件实现**
  - 在基于目录的机器上，通过硬件向量等方式来进行排队和同步控制。
  - 在基于总线的机器中要将锁从一个进程显式地传给另一个进程，软件实现会更好一些。
- **排队锁的工作过程**
  - 在第一次取锁变量失效时，失效被送入同步控制器。同步控制器可集成在存储控制器中(基于总线的系统)或集成在目录控制器中。
  - 如果锁空闲，将其交给该处理器；如果锁忙，控制器产生一个结点请求记录，并将锁忙的标志返回给处理器，然后该处理器不停地进行检测。
  - 当该锁被释放时，控制器从等待的进程排队中选出一个使用锁，这可以通过更新所选进程Cache中的锁变量来完成。

例10.6（教材2版例7.5） 如果在排队锁的使用中，失效时进行锁更新，求10个处理器完成互斥lock和unlock所需的时间和总线事务数。假设条件与前面例子相同。

解 对n个处理器，每个处理器都初始加锁产生1个总线事务，其中1个成功获得锁并在使用后释放锁，第1个处理器将有n+1个总线事务。每一个后续的处理器需要2个总线事务：1个获得锁，另1个释放锁。因此总线事务的总数为(n+1)+2(n-1)=3n-1。注意这里的总线事务总数随处理器数量成线性增长，而不是前面旋转锁那样成二次方增长。对10个处理器，共需要29个总线事务或2900个时钟周期。

```
lock（counterlock）;        // 由硬件排队“上锁”
    count=count+1;          // 已到进程数加1
unlock（counterlock）;      // 开“独占锁”
    if（count= =total）{    // 如果是最后一个进程
            count=0;        // 计数器←0
            release=1;      // 开“到齐锁”
            }
    else {                  // 如果不是最后一个进程
            spin（release=1）;    // 等待“到齐锁”打开
            }
```

总线事务（即访问主存）发生情形

原则：

(1) 写锁操作：每次均“直达”主存，如加锁、开锁、锁加1

(2) 读锁操作：在Cache更新后有一次 读失效——从主存重新调入

实例：

(1) 原子交换：EXEH

(2) 测试并置定：test_and_set

(3) 读并加1：fetch_and_increment

(4) SC原语：每次均访存

(5) LL原语：当Cache更新后有一次 读失效——从主存重新调入